

BCI Competition IV Dataset 2a / 2b

EEG 数据 Pipeline 汇报

当前成果、数据质量可视化、存在问题与后续展望

关键词：MOABB、official/session split、train-only 标准化、PyTorch DataLoader、EEGNet / EEGNeX 接口

生成日期：2026-09-08

1. 当前已经完成的成果

- 完成 Dataset 2a / Dataset 2b 的统一处理流程，覆盖全部 9 个 subject。
- 正式数据源使用 MOABB: 2a = BNCI2014_001, 2b = BNCI2014_004。
- 正式评估协议使用 official/session split, 不再使用随机 80/20 作为 baseline 结果。
- 输出统一为 $X=[N,C,T]$ 、 $y=[N]$, 保存为 train.npz / test.npz / meta.json。
- PyTorch DataLoader 支持 native / eegnet / eegnex 三种输入格式。
- 防泄漏: 先 split, 再只用 train 计算 mean/std; test 只 transform。
- 质量检查结果: 18 个 subject 全部处理成功, 仅剔除 1 个 trial, bad channel candidates = 0。

交接时模型组需要知道

- processed subject 数: 2a = 9, 2b = 9
- 2a 输入: EEGNet/EEGNeX -> [B,1,22,1000]
- 2b 输入: EEGNet/EEGNeX -> [B,1,3,1000]
- 自动化测试: 24 passed

2. Pipeline 流程与评估协议




- Dataset 2a: 0train -> train, 1test -> test.
- Dataset 2b: 0train/1train/2train -> train, 3test/4test -> test.
- 正式 processed 数据不再随机切分 train/test.
- test.npz 只用于最终评估，不用于调参。

防止数据泄漏的核心



- 任何需要 fit 或估计统计量的步骤，都只能基于 train。
- 不能把 train + test 拼起来重新标准化、做 PCA/CSP、通道选择或调参。

3. 数据质量总览




- 当前质量图用于检查数据是否明显异常，不代表模型准确率。
- trial 数、类别分布、坏通道候选和通道方差比例均未发现明显问题。
- 2a subject 03 有 1 个异常 trial 被剔除，已记录在 meta.json 和 quality_summary.csv。

数据量检查: train/test trial 数





- 2a 基本为 train=288、test=288; 2a subject 03 因 QC 少 1 个 test trial。
- 2b 各 subject 的 trial 数略有差异, 这是官方数据本身差异, 不是 pipeline 错误。

质量控制：被剔除 trial 数




- 全部 18 个 subject 中，仅 2a subject 03 剔除 1 个 trial。
- 说明当前基础 QC 下没有发现大规模异常 trial。

类别分布检查



- 2a 四分类整体均衡；subject 03 的 tongue 类 test 少 1 个，是 QC 剔除造成的。
- 2b 左右手类别在每个 subject 内保持平衡。

通道稳定性检查



- 颜色表示 train-only channel std / subject median std。
- 当前没有 bad channel candidates; 2b 只有 C3/Cz/C4, 不做自动删通道或插值。

新增成果：模型接入验证与数据汇总

- 实现：Braindecode 1.5.1 的 EEGNet / EEGNeX，固定版本和默认网络参数。
- 覆盖：2a、2b 的全部 18 个被试，36 个被试/模型组合通过。
- 每个组合读取一个真实训练 batch，完成前向、交叉熵损失、反向和 Adam 更新。
- 检查输出维度、损失和梯度是否有限，并确认模型参数确实发生更新。
- 训练示例支持被试循环；每次重新创建模型和优化器，不读取 test。
- 数据汇总表包含 18 行：样本数量、类别分布、shape、划分和预处理参数。

数据集	Pipeline batch	后端实际输入	模型输出	自动化测试
2a	[8,1,22,1000]	[8,22,1000]	[8,4]	24 passed
2b	[8,1,3,1000]	[8,3,1000]	[8,2]	24 passed

适配层只移除单例维度 1，不补零、不改变 EEG 通道或时间点。

结论：指定模型可以接入数据完成训练步骤；尚未复现论文准确率。

4. 当前存在的问题与边界

- 已有最小训练入口和模型接入测试，但尚未完成正式训练与论文准确率复现。
- 尚未做 ICA、自动坏通道插值、复杂伪迹去除；这是为了保持 baseline 协议清晰、可复现。
- 2b 只有 3 个 EEG 通道，不适合做自动删通道或复杂插值。
- 本地 GDF evaluation 需要另配真实标签；当前 local 读取流程仅用于调试。
- 当前质量报告是统计检查，不是严格 SNR 定量评估。
- 后续如果加入 CSP/PCA/通道选择等 fit 型步骤，必须继续遵守 train-only 规则。
- 严格 validation：先从未标准化的官方 train 划分，再只用 inner_train 拟合统计量。

5. 后续展望

交接后优先

- 接收方按 README 安装可选模型依赖，在自己的环境运行 smoke test。
- 确定复现论文、网络实现和参数，区分接口接通与正式准确率复现。
- 用 dataset_summary.csv 记录样本数量，并说明 1 个 test trial 的 QC 剔除。

中期扩展

- 增加严格 validation：未标准化 train 先划分，统计量只在 inner_train 拟合。
- 接入 EEGNet / EEGNeX baseline 训练脚本，输出 subject-level accuracy。
- 支持跨被试实验协议，但要和 within-subject baseline 分开报告。

谨慎探索

- 2a 可探索 ICA / 坏通道修复；2b 不建议复杂通道处理。
- ERP 可作为可视化补充；WTC 更适合 EEG-sEMG 数据，不适合当前 2a/2b。
- 如要声称提高 SNR，需要先定义可复现的 SNR 指标。

6. 最终接口 Shape

- processed 文件里的数组统一为 $X=[N,C,T]$ 、 $y=[N]$ ；这里的 N 也可以写成 D ，表示当前 split 的 trial 数。
- DataLoader 会按 `batch_size` 取出 B 个 trial，所以模型实际看到的是 batch shape。
- 2a 和 2b 只统一接口，不强行统一通道数； C 分别保留为 22 和 3。

数据集	processed X	native batch	eegnet/eegnex batch	label
2a	$[N, 22, 1000]$	$[B, 22, 1000]$	$[B, 1, 22, 1000]$	$y: [N] / [B]$
2b	$[N, 3, 1000]$	$[B, 3, 1000]$	$[B, 1, 3, 1000]$	$y: [N] / [B]$

真实 processed 数据

- 2a: train $[288, 22, 1000]$; test $[287, 22, 1000] / [288, 22, 1000]$ 。
- 2b: train $[400, 3, 1000] / [420, 3, 1000] / [440, 3, 1000]$; test $[280, 3, 1000] / [320, 3, 1000]$ 。

符号说明

- N/D : 当前 npz 文件里的 trial 数，不需要手动设置。
- B : `batch_size`，由训练脚本传入。
- 1: Conv2d 输入通道维度，用于 EEGNet/EEGNeX。

7. 交接说明

推荐做法

- 调用 `get_dataloader` 读取 processed 数据。
- EEGNet/EEGNeX 使用 `eegnet` 或 `eegnex` 格式。
- 逐 subject 读取 train/test, 按 official split 报告。
- 严格验证: 先划分, 再拟合标准化。

不要这样做

- 不要重新随机划分 processed。
- 不要用 train+test 重算标准化。
- 不要强行补齐 2a/2b 通道数。
- 不要用 local GDF 做正式 baseline。

```
train_loader = get_dataloader(  
    dataset='2a', subject=1, split='train',  
    batch_size=64, model_format='eegnet'  
)
```